A nyelvtechnológia alapjai

2.
A szövegek kódolása és rendezése (meg egy kis nyelvstatisztika)

2018/2019. tanév, I. félév

A nyelvekről

Nyelvek százmillió anyanyelvi beszélővel

(forrás: Ethnologue: Languages of the World, 2005)

	Nyelv	Anyanyelvi beszélő	Második nyelvként	Összesen	Hol hivatalos nyelv?
1.	Mandarin kínai	873 millió	178 millió	1051 millió	Kína, Tajvan, Szingapúr
2.	Hindi	370 millió	120 millió	490 millió	India, Fidzsi
3.	Spanyol	350 millió	70 millió	420 millió	Argentina, Bolívia, Chile, Kolumbia, Costa Rica, Kuba, Dominika, Equador, El Salvador, Egyenlítői Guinea, Guatemala, Honduras, Mexikó, Nicaragua, Panama, Paraguay, Peru, Spanyolország, Egyesült Államok, Puerto Rico, Uruguay, Venezuela
4.	Angol	340 millió	170 millió	510 millió	Antigua és Barbuda, Ausztrália, Bahamák, Bangladesh, Barbados, Belize, Botswana, Brunei, Kamerun, Kanada, Dominika, Etiópia, Eritrea, Fidzsi, Gambia, Ghána, Grenada, Guyana, Hong Kong, India, Írország, Jamaika, Kenya, Kiribati, Lesotho, Liberia, Malawi, Maldiv-szk, Málta, Marshall-szk, Maritius, Mikronézia, Namibia, Nauru, Új Zéland, Nigéria, Pakisztán, Palau, Pápua Új Guinea, Fülöp-szk, Rwanda, Saint Kitts & Nevs, Saint Lucia, Saint Vincent & Grenadines, Samoa, Seychelles, Sierra Leone, Szingapúr, Solomo-szk, Szomália, Dél-Afrika, Sri Lanka, Swaziland, Tanzania, Tonga, Trinidad and Tobago, Tuvalu, Uganda, Egyesült Királyság, Egyesült Államok, Vanuatu, Zambia, Zimbabwe
5.	Arab	206 millió	24 millió	230 millió	Modern arab: Algéria, Bahrain, Csád, Comoros, Dzsibuti, Egyiptom, Eritrea, Irak, Izrael, Jordánia, Kuwait, Libanon, Líbia, Marokkó, Niger, Omán, Palesztina, Katar, Szaúd-Arábia, Szomália, Szudán, Szíria, Tunézia, Egyesült Arab Emirátusok, Nyugat- Szahara, Jemen. Hasaniya-arab: Mauritánia, Szenegál
6.	Portugál	203 millió	10 millió	213 millió	Angola, Brazília, Zöldfoki-szk, Kelet- Timor, Bissau- Guinea, Makaó, Mozambik, Portugália, São Tomé & Príncipe
7.	Bengáli	196 millió	19 millió	215 millió	Bangladesh, India
8.	Orosz	145 millió	110 millió	255 millió	Grúzia (Abházia), Fehéroroszország, Kazahsztán, Kirgizisztán, Oroszország, Moldávia (Nyeszteren túli terület)
9.	Japán	126 millió	1 millió	127 millió	Japán, Palau
10.	Német	101 millió	128 millió	229 millió	Ausztria, Belgium, Németország, Olaszország (Dél-Tirol), Liechtenstein, Luxembourg, Lengyelország, Svájc

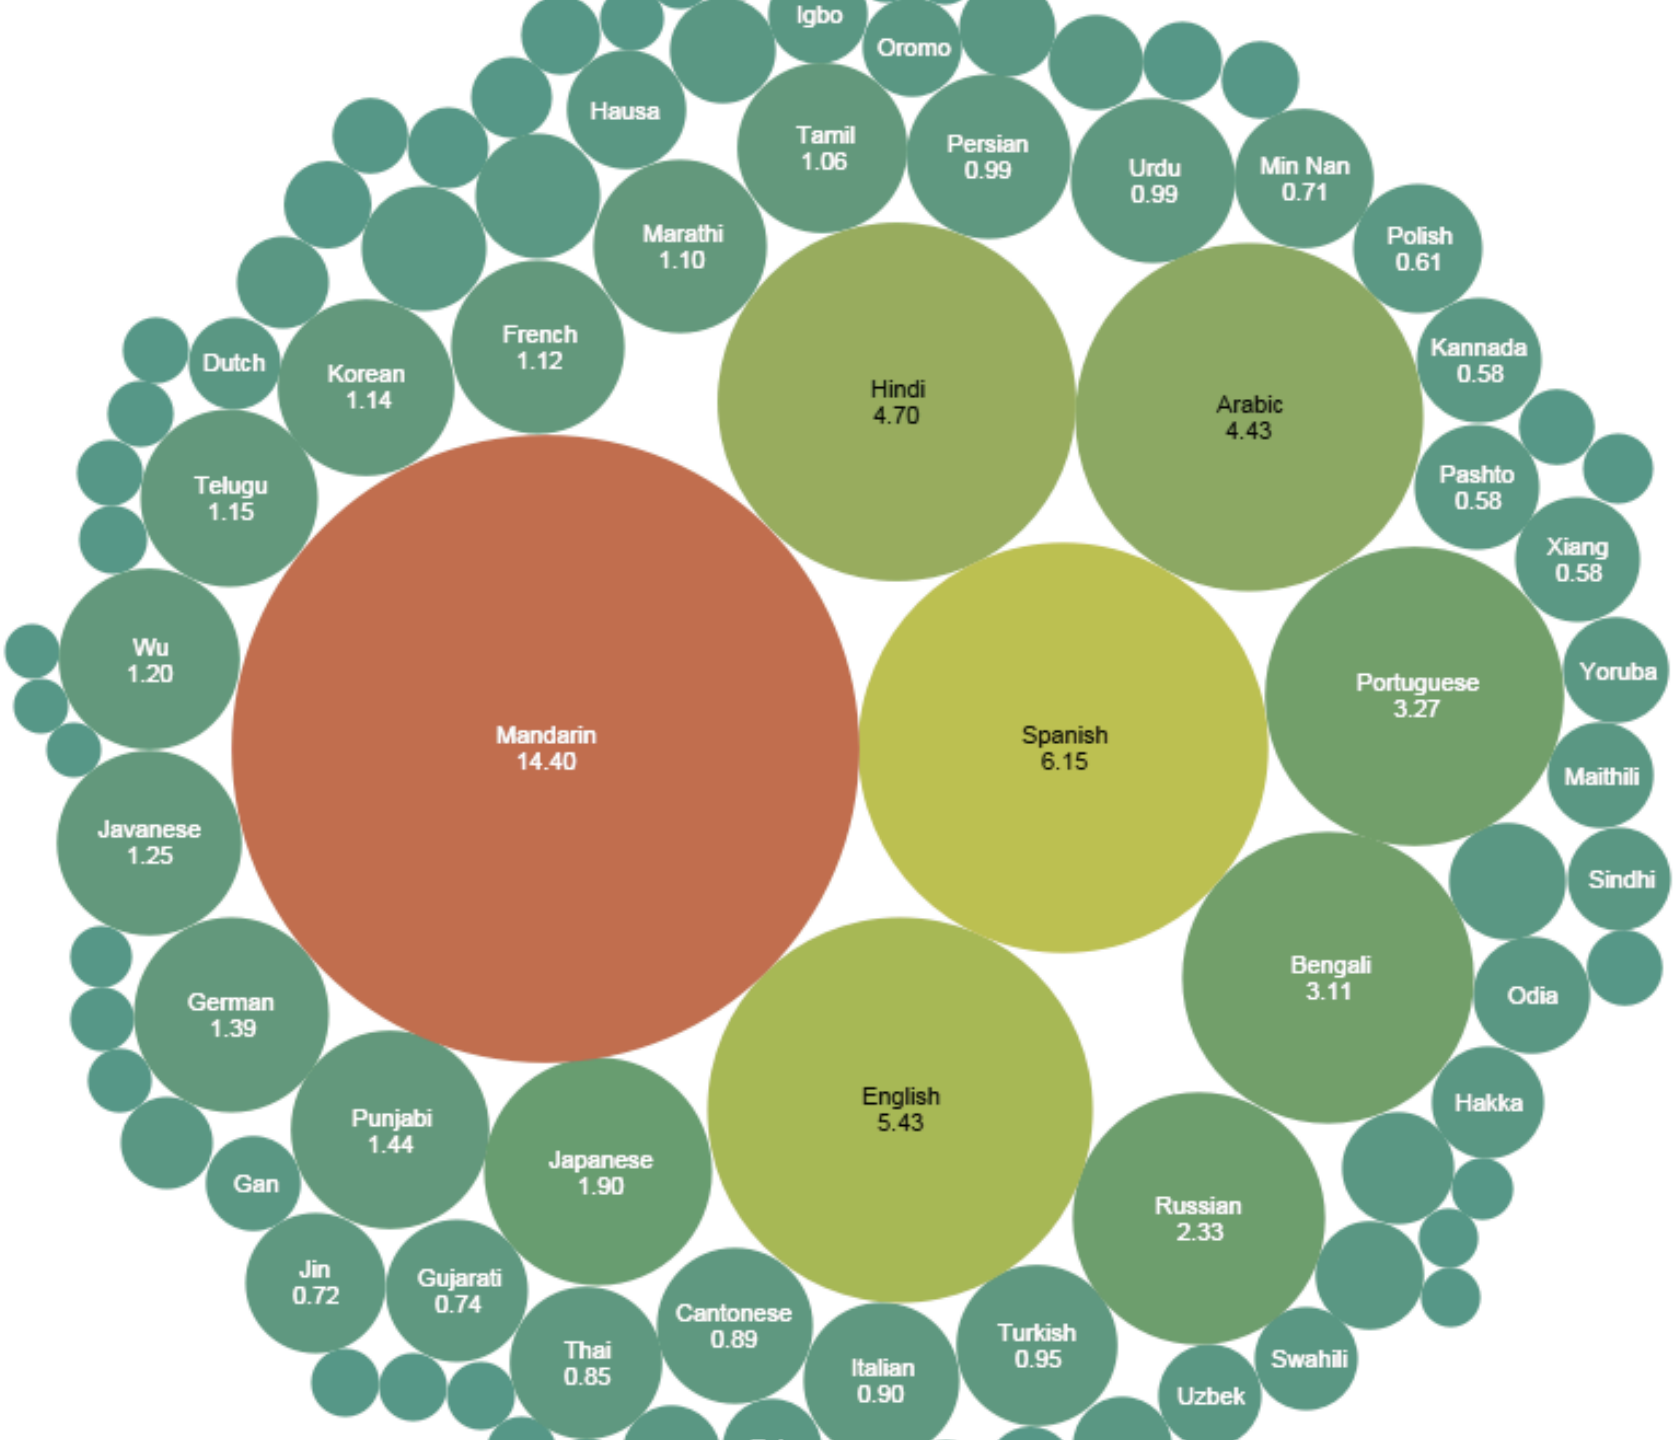
Igbo
Oromo
Hausa
Tamil
1.06
Persian
0.99
Urdu
0.99
Min Nan
0.71
Polish
0.61
Marathi
1.10
Kannada
0.58
French
1.12
Hindi
4.70
Arabic
4.43
Dutch
Korean
1.14
Pashto
0.58
Telugu
1.15
Xiang
0.58
Wu
1.20
Mandarin
14.40
Spanish
6.15
Portuguese
3.27
Yoruba
Maithili
Javanese
1.25
Sindhi
Bengali
3.11
German
1.39
Odia
English
5.43
Punjabi
1.44
Hakka
Japanese
1.90
Gan
Russian
2.33
Jin
0.72
Gujarati
0.74
Cantonese
0.89
Turkish
0.95
Thai
0.85
Italian
0.90
Swahili
Uzbek

A magyar nyelv „helye”

(forrás: Ethnologue: Languages of the World, 2010)

...

57. Cebuano (Fülöp-szk)
58. Sinhala (Sri Lanka)
59. Rangpuri (Bangladesh)
60. Északkelet-thai (Thaiföld)
61. Zhuang (Kína)
62. Malgas (Madagaszkár)
63. Nepáli (Nepál)
64. Szomáli (Szomália)
65. Khmer (Kambodzsa)
66. Madura (Indonézia)
67. Görög (Görögország)
68. Csittagóniai (Bangladesh)
69. Haryanvi (India)
70. Magahi (India)
71. Dekkan (India)
72. Magyar

...

A nyelvek területi megoszlása

(forrás: Ethnologue: Languages of the World, 2012)

Földrész	Élő nyelvek		Beszélők		
	száma	%	száma	%	ny -kénti átlag
Afrika	2 146	30,2	789 138 977	12,7	367 726
Amerika	1 060	14,9	51 109 910	0,8	48 217
Ázsia	2 304	32,4	3 742 996 641	60,0	1 624 565
Európa	284	4,0	1 646 624 761	26,4	5 797 975
Óceánia	1 311	18,5	6 551 278	0,1	4 997
Összesen	**7 105**	**100.0**	**6 236 421 567**	**100.0**	**877 751**

A nyelvek anyanyelvi beszélők szerinti megoszlása

(forrrás: Ethnologue: Languages of the World, 2009)

Populáció	Élő nyelvek			Beszélők		
	száma	%	Σ %	száma	%	Σ %
100 000 000 to 999 999 999	8	0,1	0 ,%	2 308 548 848	40,20	40,20%
10 000 000 to 99 999 999	82	1,2	1,3%	2 480 078 977	39 42	79,62%
1 000 000 to 9 999 999	304	4,3	5,5%	951 916 458	14,55	94,18%
100 000 to 999 999	895	13,0	18,6%	283 116 716	4 75	98,84%
10 000 to 99 999	1 824	26,4	45,0%	60 780 797	1 01	99,86%
1 000 to 9 999	2 014	29,2	74,1%	7 773 810	0 13	99,99%
100 to 999	1 038	15,0	89,2%	461 250	0 00	99,99%
10 to 99	339	4,9	94,1%	12 560	0 00	99,99%
1 to 9	133	1,9	96,0%	521	0 00	100,00%
Ismeretlen	277	4,0	100,0%			
Összesen	**6 909**	**100,0**		**5 959 511 717**	**100,0**	

A nyelvi gépi feldolgozásának szintjei

A szó

- Definíciója nincs
- **Fonológiai szó**
  (pl. *ház+am* fonológiai szó,
  de az összetett szavak nem ilyenek)
- **Lexikai szó (lexéma)**
  (pl. a *számítógépezés* szó nem lexéma,
  mert levezethető alkotóelemei jelentéséből)
- **Morfológiai szó**
  (pl. *láttam volna*)
- **Szintaktikai szó**
  (pl. *szép+ség+e+im*,
  de az igekötős ige nem ilyen,
  mert a szintaxis megváltoztatja az alakját)

Még nehezebben azonosítható nyelvi egységek

- **Morféma:** a nyelv legkisebb jelentéssel bíró alkotórésze; nincs természetes határa
- **Szószerkezet, frázis:**
  nincs természetes határuk; egyrészt lexémák, másrészt mondat alatti egységek
- **Megnyilvánulás, mondat:**
  írásban egyszerűbb (nem nehéz a formális definíció)
- **Szöveg**:
  mondatok sora, melyben az összefüggések túlmutatnak a mondatnyelvtanokon
- Megkülönböztetendők: **type** és **token**

Hang, fonéma, betű, karakter

Fonéma

- **Szembenállás**
  Ha két beszédhang egyikének a helyére behelyettesítjük a másikat, és más szótári egységet kapunk eredményül, a két beszédhangot két különböző fonémához soroljuk:
  géz, kéz, méz, néz, réz ->/g/, /k/, /m/, /n/, /r/
- **Kiegészítő eloszlás**
  Ha két beszédhang mindig csak egymást kölcsönösen kizáró környezetekben fordul elő, feltételesen ugyanazon fonémához sorolhatjuk őket:
  pl. *hó : doh* -> ún. allofónok

Fonéma (2)

- **Fonetikai hasonlóság**
  Az előző két ismérv önmagában nem zárja ki a téves fonémaazonosítás lehetőségét,
  pl. a veláris nazális nemcsak a dentális nazálissal, hanem más hangokkal is a kiegészítő eloszlás viszonyában van, mégsem soroljuk sem pl. a /h/-hoz vagy a /j/-hez, hanem csakis az /n/-hez
- **Szabad váltakozás**
  Ha két beszédhang ugyanazon környezetben egymással helyettesíthető anélkül, hogy a szóban forgó szótári elem azonossága veszélyben forogna, ugyanazon fonéma szabad változataival állunk szemben

Fonetikus ábécé

- Az IPA a latin (angol) ábécén alapszik
- A legtöbb latin betűs nyelv ugyanúgy ejt többet is: [b], [d], [f], [h], [k], [l], [m], [n], [p], [t], [v] stb.
- Vannak közöttük olyanok, melyek kiejtése a legtöbb latin betűvel író nyelvben eltér: [j], [r], [y] stb.
- Vannak olyan jelek, melyeket a latin betűk átalakításával hoztak létre, vagy írott formájukat használják: [ɛ], [ɜ] stb.
- Bizonyos elemeket a görög ábécéből vettek: [β], [ɣ], [ɛ], [θ], [χ], [ʊ] stb.
- A magyar nyelv 14 magánhangzó- és 24 mássalhangzó-fonémája az IPA rendszerben is megjeleníthető

IPA-karakterkészletek

- SIL: Summer Institute of Linguistics
- Charis SIL: teljes IPA, tonális mellékjelek és sok más kevésbé általános fonetikai jel is
- Doulos SIL (a Charis SIL, csak bold és italics nélkül)
- SIL93: a korábbi SIL IPA93 betűtípusok (Manuscript és Sophia) Unicode-ban újrakódolva

Az „extra kódolás” igénye

- Nem elég a latin ábécé
- Diakritikus jelek: „kidíszítjük” a meglevőket
- Multigráfok: kombináljuk a meglevőket

- Pl. amit a magyar „s” betűvel jelöl:

s	magyar
sh	angol, albán, cigány
ch	francia, portugál
sch	német
si	gael, indonéz
sci	olasz
skj	svéd, norvég
š	cseh, szlovák, horvát, szlovén, lett, litván, észt
sz/ś	lengyel
ş	román, török
ŝ	eszperantó

Európai ékezetes betűk (1)

Nyugat

àáâãäåæăèéêëìíîïòóô
õöøœùúûüŵýÿŷ
çl·ñŕşţðþß

Európai ékezetes betűk (2)

Kelet

áâäāąéëēėęěíîīįıóôõö
ōőúûüūŭůűųý
çćĉċčď’đĝğġģĥħĵķĺļľł
ńņňŕŗřśŝşšť’źżž

Diakritikumok multigráfos kódolásai

- e-mail:
  arvizturo tukorfurogep
  (fokabel???)
- távirati:
  aarviiztuuerooe tuekoerfuuroogeep
- repülő ékezetes:
  a’rvi’ztu”ro” tu:ko:rfu’ro’ge’p
- számkódos:
  a1rvi1ztu3ro3 tu2ko2rfu1ro1ge1p
- TeX:
  \’arv\’izt\Hur\Ho t\”uk\”orf\’ur\’og\’ep
- HTML:
  árvíztűrő

Karakter, karakterkód, karakterkészlet

- **Karakter**: absztrakt objektum, a számítógépen tárolt szövegek legkisebb, tovább nem bontható egysége, Egy karakter egy betű, szám, írásjel, speciális jel, illetve egyetlen egyszerűbb szövegformázó parancs ábrázolására alkalmas
- **Karakterkód:** a karakternek mint absztrakt objektumnak megfeleltetett számkód, amely számítógépen közvetlenül ábrázolható
- **Karakterkészlet:** karaktereket és számkódjaikat összerendelő táblázat, Meghatározza, hogy milyen karakterek használhatók, és azt is, hogy az egyes karakterkódokat miképpen kell értelmezni. A karakterkészlet megjeleníthető karaktereket és speciális műveleteket előíró vezérlőkaraktereket tartalmaz
- **Kódlap**: több karakterkészletet is kezelő számítógéprendszerben egy saját számkódjával azonosított karakterkészlet
- **Betűkészlet**: olyan táblázat, amely adott karakterkészlet(ek) megjeleníthető karaktereihez karakterképeket rendel, amelyek a számítógép képernyőjén vagy nyomtatásban jelennek meg. Az alkalmazott betűkészlet a szöveg számítógépbeli értelmezésére – például a szöveget nyelvi szempontból feldolgozó programokra – nincs befolyással, csak annak megjelenítésekor használatos

Kódlapok

ASCII kódtábla:

ASCII-Zeichensatz										
+	0	1	2	3	4	5	6	7	8	9
30				!	"	#	$	%	&	'
40	(	)	*	+	,	-	.	/	0	1
50	2	3	4	5	6	7	8	9	:	;
60	<	=	>	?	@	A	B	C	D	E
70	F	G	H	I	J	K	L	M	N	O
80	P	Q	R	S	T	U	V	W	X	Y
90	Z	[	\	]	^	_	`	a	b	c
100	d	e	f	g	h	i	j	k	l	m
110	n	o	p	q	r	s	t	u	v	w
120	x	y	z	{	|	}	~			

Kódlapok (2)

Az ISO 8859-2 (Latin-2) kódtábla:

- magyar
- német
- horvát
- lengyel
- román
- szlovák
- szlovén
- szerb
- cseh
- albán

iso-8859-2										
+	0	1	2	3	4	5	6	7	8	9
160		Ą	˘	Ł	¤	Ľ	Ś	§	¨	Š
170	Ş	Ť	Ź	-	Ž	Ż	°	ą	˛	ł
180	´	ľ	ś	ˇ	¸	š	ş	ť	ź	˝
190	ž	ż	Ŕ	Á	Â	Ă	Ä	Ĺ	Ć	Ç
200	Č	É	Ę	Ë	Ě	Í	Î	Ď	Đ	Ń
210	Ň	Ó	Ô	Ő	Ö	×	Ř	Ů	Ú	Ű
220	Ü	Ý	Ţ	ß	ŕ	á	â	ă	ä	ĺ
230	ć	ç	č	é	ę	ë	ě	í	î	ď
240	đ	ń	ň	ó	ô	ő	ö	÷	ř	ů
250	ú	ű	ü	ý	ţ	˙				

A Unicode és a UCS

- UCS: Universal Character Set
- Unicode szabvány: 16 biten tárolt síkokra osztja a – szabvány legutóbbi változatában rögzített – kb. 100 ezer karaktert
- Minden beszélt, holt és egyéb nyelv (pl. Braille) karakterei (betűk, számok, írásjelek stb.)
- Minden egyes karakternek egyedi száma és neve van:

U+0041	Latin capital letter A
U+0151	Latin small letter o with double acute

- Eredetileg 2 bájton (16 biten) tárolta az adatokat (Basic Multilingual Plane) , de ez nem volt elég, ezért 4 bájtosra (32 bitesre) bővítették

A Unicode és a UCS

- UTF-8 (Unicode Transformation Format): változó hosszúságú kódolással (1–6 bájt) képezi le a Unicode karaktertáblát, pl. 1 bájton tárolt kódjai az ASCII-nak felelnek meg, így a latin betűs UTF-8 kódolású szövegek a régi ASCII környezetben is olvashatóak maradnak
- UTF-16: 1 112 064 karaktert kódol
- UCS-2 (elavult), 2 bájton (UTF-16 részhalmaza)
- UCS-4: 4 bájton (31-bit) = UTF-32, ISO 10646

A Unicode és a UCS

- 1980-as évek: igény egy egységes, minden karaktert leíró kódtáblára
  - **ISO 10646** – az ISO szervezet szabványa
  - **Unicode** – amerikai cégek konzorciuma
- 1991: egyesítik a két projekt eredményeit, de megmarad a két szervezet
- Teljesen kompatibilisek azóta is!
- Különbségek is vannak: az ISO 10646 csak karakterkészlet, a Unicode-ban viszont léteznek további kiegészítések, pl. egyeztetési szabályok

Egészen pontosan…

- ISO/IEC 10646-1:1993 ≈ Unicode 1.1
- ISO/IEC 10646-1:2000 ≈ Unicode 3.0
- ISO/IEC 10646-2:2001 ≈ Unicode 3.2
- ISO/IEC 10646:2003 ≈ Unicode 4.0
- ISO/IEC 10646:2003 és az 1. kiegészítés ≈ Unicode 4.1
- ISO/IEC 10646:2003 és
  az 1. kiegészítés,
  a 2. kiegészítés, és részben
  a 3. kiegészítés ≈ Unicode 5.0
- Unicode 7.0 (2014. június)
- Unicode 8.0 (2015. június)
- Unicode Character Database:
  http://www.unicode.org/Public/UNIDATA/
- Továbbá: http://www.decodeunicode.org/

Ábécék és rendezési elvek

Az ábécék „eleje”

1. latin, 2. görög, 3. cirill, 4. héber, 5. arab, 6. örmény, 7. régi grúz, 8. mai grúz, 9. dévanagári, 10. bengáli, 11. gurmukhi, 12. gudzsaráti, 13. orijá, 14. tamil, 15. telugu, 16. kannada, 17. malajalám, 18. thai, 19. lao, 20. hiragana, 21. katakana, 22. bopomofo, 23. koreai, 24. kínai

Ábécék és rendezés

- A kiejtés szerinti írás (?)
- Az ábécébe rendezés elvei
- Átjárás ábécék között: transzliterálási problémák
- A könyvtári rendezés

  Az olyan sajátos célú munkák (lexikonok, enciklopédiák, atlaszok és térképek névmutatói stb.), amelyekben magyar és idegen nyelvű szóanyag erősen keveredik egymással, rendszerint az úgynevezett általános latin betűs ábécét követik: *a, b, c, d, e, f, g, h, i, j, k, l, m, n, o, p, q, r, s, t, u, v, w, x, y, z,* Ebben a rendszerben mind a magyar, mind az idegen többjegyű betűknek minden egyes eleme külön, önálló egységnek számít, és a besorolás nincs tekintettel sem a magyar ékezetekre, sem az idegen betűk mellékjeleire. Az ilyenfajta munkák szavainak betűrendbe sorolása bonyolult feladat, Itt például a több szóból álló egységeket vagy az egész kapcsolat, vagy csak az első elem alapján szokás besorolni, ahogyan a könnyebben kezelhetőség érdeke vagy egyéb szempont kívánja. A követendő eljárást a könyvtárügy és a szakirodalmi tájékoztatás (dokumentáció) területén szabvány (MSZ 3401) írja elő, illetőleg belső szakmai útmutatók szabályozzák.

A magyar akadémiai rendezés (1)

A különböző betűvel kezdődő szavakat az első betűk ábécébeli helye szerint állítjuk rendbe, illetőleg keressük meg

Példa:

acél, cukor, csók, gép, hideg, kettes, olasz, öröm, Nagy, nyúl, remény, sokáig, szabad, Tamás, vásárol

A magyar akadémiai rendezés (2)

Az egyjegyű betűt teljesen elkülönítjük az azonos írásjeggyel kezdődő, de külön mássalhangzót jelölő kétjegyű (ill, háromjegyű) betűtől: mindig az egyjegyű betű van előbb

Példa:

cudar, cukor, cuppant, csalit, csata, Csepel
dac, domb, duzzog, dzsem, dzsungel, Zoltán, zongora, zúdul, zsalu, zseni

A magyar akadémiai rendezés (3)

A többjegyű betűk kettőzött változatait sohasem az egyszerűsített alakok szerint soroljuk be a betűrendbe, hanem a megkettőzött betűt mindig két külön betűre bontjuk, s így soroljuk a szót a megfelelő helyre (*ccs = cs + cs; ggy = gy + gy; ddzs = dzs + dzs*)

Példa:

kas, Kassák, kastély, kaszinó, kassza, kaszt
mennek, menü, menza, Menyhért, mennyi,
nagy, naggyá, nagygyakorlat, naggyal, nagyít

A magyar akadémiai rendezés (4)

A magánhangzók rövid és hosszú változatát jelölő betűk *(a – á, e – é, i – í, o – ó, ö – ő, u – ú, ü – ű)*
a kialakult szokás szerint mind a szavak elején, mind pedig a szavak belsejében azonos értékűnek számítanak a betűrendbe sorolás szempontjából.
A magánhangzó hosszú változatát tartalmazó szó tehát meg is előzheti a rövid változatút

Példa:

ír, Irak, Irán, írandó, iránt, író, iroda, irónia

A magyar akadémiai rendezés (5)

A rövid magánhangzós szó kerül viszont előbbre olyankor, ha két szó betűsora csak az azonos magánhangzók hosszúsága tekintetében különbözik

Példa:

égbolt, Eger, egér, éger, égés, egész,
keres, kérés, koros, kóros, kórós,
szel, szél, szelel, szeles, szelés, széles, szelet

A magyar akadémiai rendezés (6)

A különírt elemekből álló szókapcsolatokat és az egybeírt vagy kötőjellel kapcsolt összetételeket minden tekintetben olyan szabályok szerint soroljuk betűrendbe, mint az egyszerű szavakat, A szóhatárokat tehát nem vesszük figyelembe. Ugyanez a szabály érvényes a közszavak közé besorolt tulajdonnevekre is

Példa:

Kis részben, kissé, Kiss Ernő, kis sorozat, kissorozat-gyártás, kis számban, kistányér, kis virág, tiszafa, Tiszahát, Tisza Kálmán, Tisza menti, Tiszántúl, Tisza-part, tiszavirág, tiszt

A magyar akadémiai rendezés (7)

A betűrendbe soroláskor a szokásostól némiképp eltérően kezeljük a régies írású magyar családnevekben, valamint az idegen szavakban és tulajdonnevekben előforduló régi magyar, illetőleg idegen betűket

Példa:

Czibere, Czuczor, Cházár, Császár, Cselényi

Régies és idegen hangjelölés

- *aa* = á: *Gaal* [e : gál]
  ch = cs: *Madách* [e : madács]
  eé = é: *Veér* [e : vér]
  cz = *c: Czuczor* [e : cucor]
  eő = ö: *Eötvös* [e : ötvös]
  s = zs: *Jósika* [e : józsika]
  ew = ö: *Thewrewk* [e : török]
  th = t: *Csáth* [e : csát]
  oó = ó: *Soós* [e : sós]
  ts = cs: *Takáts* [e : takács]
  y = i: *Kölcsey* [e : kölcsei] stb
  w = v: *Wesselényi* [e : veselényi] stb
- angol: *Greenwich* [e : grinics], *joule* [e : dzsúl]
- cseh: *Dvořák* [e : dvorzsák], *Škoda* [e : skoda]
- francia: *Eugėne* [e : özsen], *Nîmes* [e : nim]
- német: *Schäfer* [e : séfer], *Werther* [e : verter]
- olasz: *Bologna* [e : bolonya], *quattrocento* [e : kvatrocsentó]
- portugál: *Guimarães* [e : gimarajs], *piranha* [e : piránya]
- román: *Tîrgovişte* [e : tirgoviste], *piaţa* [e : piaca]
- szerbhorvát: *Đurić* [e : gyúrity], *Živogošće* [e : zsivogostye]

Továbbá…

1-szer 1 az 1
II. János Pál
10 kérdés a személyi jövedelemadóról
11. Távhő-konferencia
XIX. század
88 kérdés az AIDS-ről
8000 germanizmus
ABALKIN, L. I.
Aczél György
ACÉLOK

Nyelvstatisztikai alapok

Betűstatisztikák

- Hangstatisztikák, betűstatisztikák
- Titkosírás-megfejtések
- Morse-ábécé, írógép-billentyűzet
- A nyelvek tipizálhatók n-gráfjaik alapján (pl. mássalhangzó-torlódással kezdődő szavaink régen egyáltalán nem voltak, és ma is csak bizonyosak vannak)
- Információ (Shannon): kisebb valószínűségű üzenetnek az információtartalma nagyobb, és független események együttes információtartalma az események információtartalmának összege

Egy kis információelméleti háttér

- Shannon (1949): tfh egy kommunikációs folyamatban veszünk részt, melynek csatornáján az X halmaz jeleiből összetevődő véges sorozatok, üzenetek áramlanak
- Ha elég sok üzenet áll rendelkezésre, akkor mérni tudjuk azt a p(x) valószínűséget, hogy adott $x \in X$ elem milyen gyakran fordul elő várhatóan egy üzenetben
- Az x jel információtartalma: $I(x) := p(x)\log_2[p(x)^{-1}]$
- Az $\underline{X}$ üzenet információtartalma is:
  ha $\underline{X} = (x_1,x_2,\ldots,x_j) \in \underline{X}^i$ jelek sorozata, akkor
  $H(\underline{X}) = H(x_1,x_2,\ldots,x_j) = I(x_1)+I(x_2)+\ldots+I(x_j) =$
  $= p(x_1)\log_2 p(x_1)^{-1} + p(x_2)\log_2 p(x_2)^{-1} + \ldots + p(x_j)\log_2 p(x_j)^{-1}$
- Shannon (1951): Prediction and Entropy of Printed English

n-gramok

- n-gram: egymás után következő n db karakter egy szövegben
- Az n-gramok lehetnek szavak is, de nem feltétlenül azok
- Az n-gramok használatának előnye, hogy nyelvfüggetlen és hibatűrő megoldások megvalósítására igen alkalmas
- Stochastic Language Models (N-Gram) Specification: http://www.w3.org/TR/ngram-spec/
- Microsoft Web N-gram Services: http://research.microsoft.com/en-us/collaboration/focus/cs/web-ngram.aspx
- Google N-gram Viewer: http://books.google.com/ngrams

Magyar betűstatisztika (1-gramok)

	Gyakoriság	Információ bitben
A	9,35	3,43
Á	3,72	4,77
B	1,72	5,87
C	0,60	7,40
D	1,71	5,90
E	9,71	3,37
É	3,87	4,71
F	0,88	6,87
G	3,55	4,83
H	1,23	6,37
I	4,39	4,53
J	1,21	6,39
K	5,35	4,24
L	6,30	4,00
M	3,92	4,69

	Gyakoriság	Információ bitben
N	5,47	4,21
O	4,47	4,50
Ö	2,14	5,57
P	1,04	6,61
Q	0,00	?
R	4,22	4,58
S	6,57	3,94
T	7,87	3,68
U	1,29	6,30
Ü	0,93	6,77
V	1,81	5,81
W	0,00	?
X	0,01	13,33
Y	2,21	5,52
Z	4,46	4,50

n-gramok a gyakorlatban

Küpfmüller (1954) szöveggenerálása
1-, 2-, 3- és 4-gramokkal:

1. EME GKNEET ERS TITBL VTZEN
2. AUSZ KEINU WONDINGLIN DUFRN
3. PLANZEUNDGES PHIN INE UNDEN
4. ICH FOLGEMASZIG BIS STEHEN DISPONIN

n-gramok a magyarban

1. nórmlgenytnaeőettesy sdrúk üze neée issgnis k, őentetnsmrdttca.
2. Bégiz érj, ercszépot, ekalfönembenyett kmáb os alőrre.
3. Ezenlapoltike lehátszökmég hog, aztradon két. Korcsant ván.
4. Hárone – Az a léhez, meg, akarózsák hogy öregész egény látán, járnagyon kérdeket egy emberet. Tordárd sem tan.
5. Senki adsaadott, hogy egy ki tornak, a kapta a mielőtte szor ismerni most vele aótsap a eipővel. - Ó, biztosítás úr csak társallatság vele. Hallj ott.
6. Történik. Telt év óta meglátta bevallott kissé lehajtott és mindig, légéz erligyúneáenl eltűnt.

Megfigyelhető: a 4, után itt nem javul igazán a minőség, Miért?

Mert kicsi tanítókorpusz esetén (esetünkben 8 Mbájt) a négyesnél nagyobb csoportok eloszlásának megbízhatósága már nem elegendő

Zipf-törvény

- G. K. Zipf az 1930-as években vette észre: ha egy szövegben összeszámoljuk az egyes szavak előfordulási gyakoriságát, majd sorba rendezzük őket gyakoriságuk alapján, és ábrázoljuk a gyakoriságot rang szerint (azaz annak a függvényében, hogy az illető szó hányadik a sorban), akkor (közelítéssel) egy hatványfüggvény szerint lecsengő görbét kapunk -1-hez közeli kitevővel
- Tehát a lista i-edik elemének gyakorisága: $R_i \sim \frac{1}{i^\alpha}$
  (α a korpuszra jellemző, 1 körüli konstans)
- Következmény: ha a leggyakoribb szavakat tartjuk csak meg, a korpusz nagy része megmarad
- A jelenség az emberi nyelvek univerzális tulajdonságának bizonyult: pl. hasonló viselkedést kapunk, ha nem a szavakat, hanem az összefüggő szöveg n-gramjait vizsgáljuk

Heaps-törvény

- Heaps (1978): egy N szóból álló korpusz esetén a különböző szavak száma:

$$V \approx K \cdot N^{\beta}$$

K: a szövegtől függő konstans (10≤K≤100)
β: a szövegtől függő konstans
(angolnál: 0,4≤ β ≤0,6 - magyarnál: 0,6≤ β ≤0,7)

- Következmény: egy korpuszban a különböző szavak száma új dokumentumok hozzáadásával folyamatosan növekszik (pl. az elírásoknak, a tulajdonneveknek és az új szavaknak köszönhetően), de ez a növekedés szublineáris, azaz az új szavak nem lesznek gyakori szavak

További statisztikai nyelvtörvények

- Mandelbrot: összefüggés van a szavak hosszúsága és rangja között is, ui. a rövidebb szavak minden nyelvben sokkal nagyobb gyakorisággal fordulnak elő, mint a hosszabbak, méghozzá a rangjuk a hosszal fordítottan arányos
- Észrevétel: ha a történelmi fejlődés során egy szó gyakorisága megnő, rendszerint meg is rövidül
- Következmény: nyelveink legősibb rétegét (pl. a testrészek neveit) szinte kivétel nélkül egytagú, két-három fonémából álló szavak alkotják
- *„Matematikai igazság, hogy kinek két szótagú neve van, fél annyi kortessel választathatik meg, mint az, kinél négy szótagot kell kiáltani "*

(Eötvös: A falu jegyzője)

Eyg éredkes jleneség

Egy anlgaii etegyem ktuasátai szenirt nem szímát melyin serenrodbn vnanak a bteűk egy szbóan, az etegyeln ftonos dloog, hogy az eslő és az ultosó bteűk a hölyeükn lneegyek. A tböbi bteű lheet tljees összevabisszásagn, mgiés porbléma nlkéül oalvsahtó a szveög. Eennk oka, hogy nem ovalusnk el mniedn bteűt eygenknét, hneam a szót ovlasusk a mgaa eszgébéen.

Szövegek és nyelvek a weben

Az indexelt web mérete

(milliárd weboldalban)

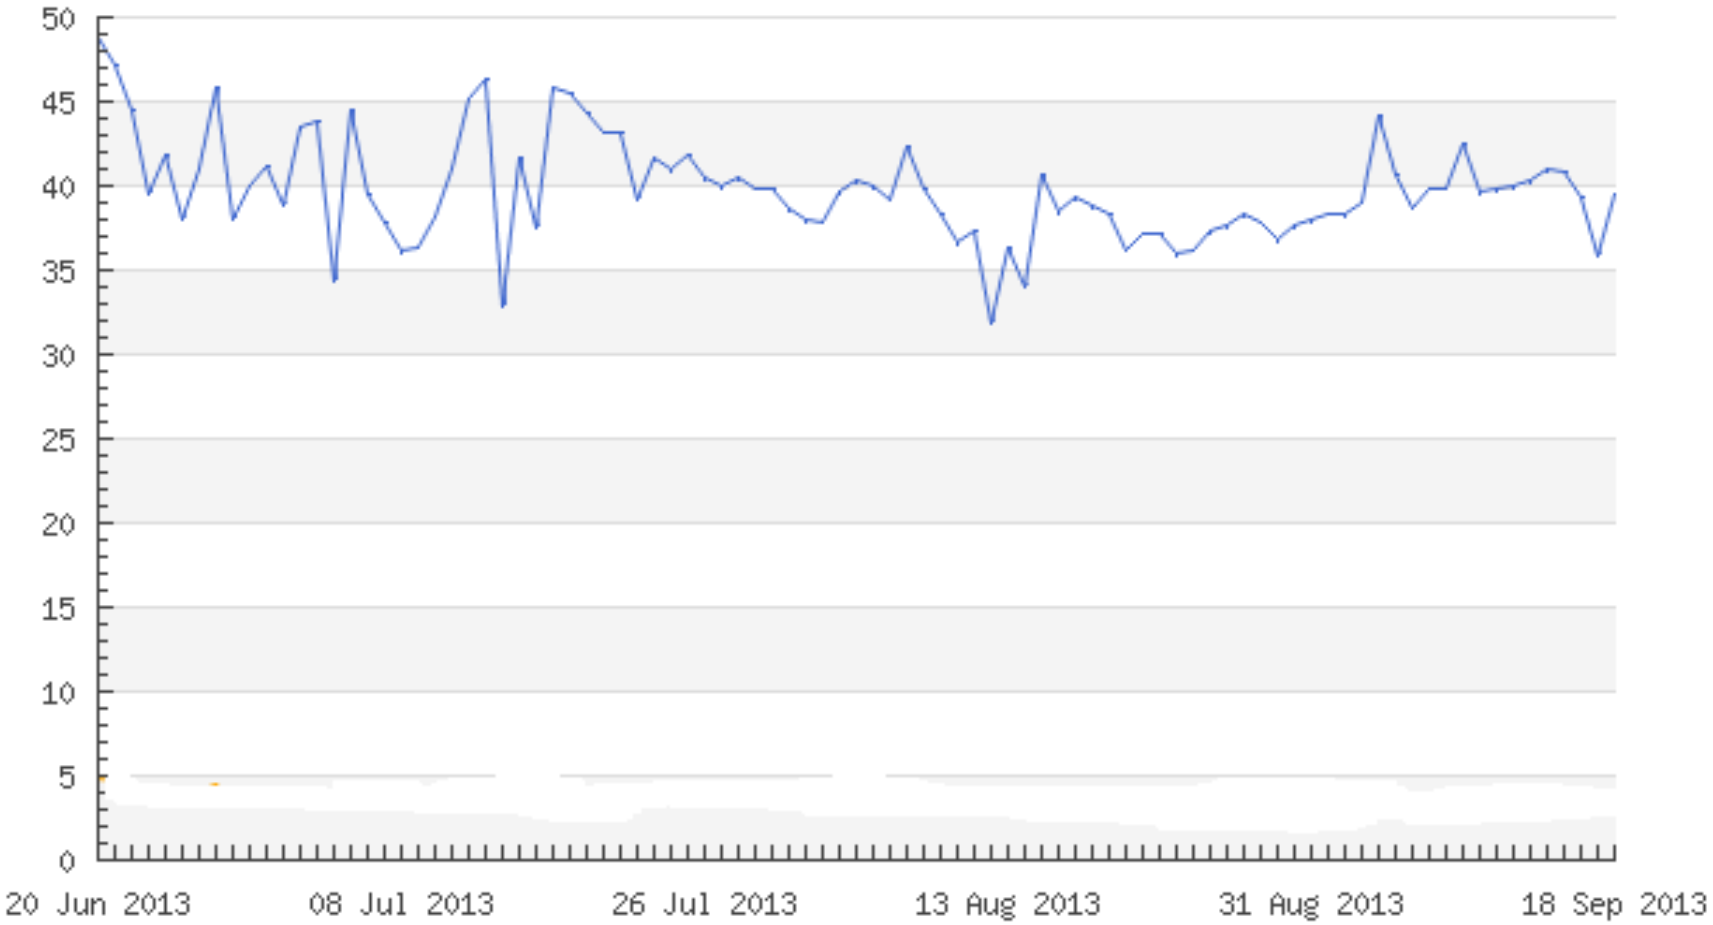

A web és a nyelvek

Nyelv	Internet-használók	Internet-penetráció	Növekedés 2000-2011	Internet-használók a világ %-ában	Népesség
Angol	**565 004 126**	43,4 %	301,4 %	26,8 %	1 302 275 670
Kínai	**509 965 013**	37,2 %	1478,7 %	24,2 %	1 372 226 042
Spanyol	**164 968 742**	39,0 %	807,4 %	7,8 %	423 085 806
Japán	**99 182 000**	78,4 %	110,7 %	4,7 %	126 475 664
Portugál	**82 586 600**	32,5 %	990,1 %	3,9 %	253 947 594
Német	**75 422 674**	79,5 %	174,1 %	3,6 %	94 842 656
Arab	**65 365 400**	18,8 %	2501,2 %	3,3 %	347 002 991
Francia	**59 779 525**	17,2 %	398,2 %	3,0 %	347 932 305
Orosz	**59 700 000**	42,8 %	1825,8 %	3,0 %	139 390 205
Koreai	**39 440 000**	55,2 %	107,1 %	2,0 %	71 393 343
Σ	**1 615 957 333**	36,4 %	421,2 %	82,2 %	4 442 056 069
A többi	**350 557 483**	14,6 %	588,5 %	17,8 %	2 403 553 891
Összesen	**2 099 926 965**	30,3 %	481,7 %	100,0 %	6 930 055 154

A weblapok nyelvei

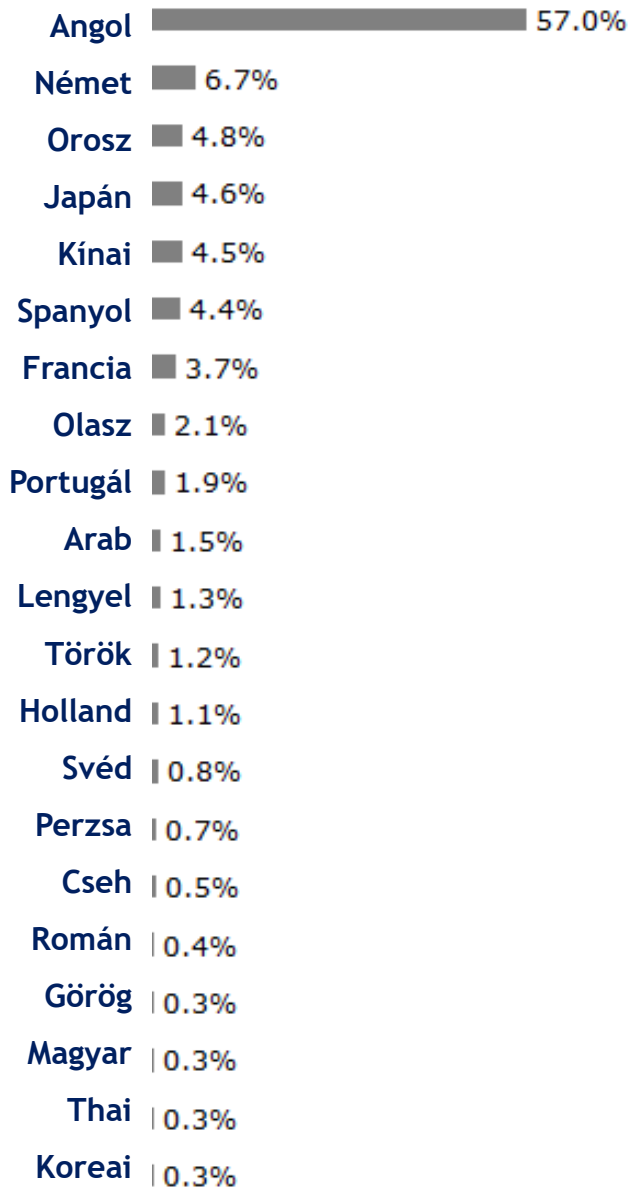

Következmények

1. Az internetes tartalom több mint a fele angol
2. Az internethasználók háromnegyedének az anyanyelve nem angol
3. 1+2 → A nem-angol anyanyelvűek világában a web angol tartalmának egyre nagyobb része jelenik meg
4. 3 → Aki a webet olvassa, az növekvő számban nem-angol anyanyelvű; aki pedig a webes tartalmat közzéteszi, az csökkenő részben angol anyanyelvű
5. 4 → A nem-anyanyelvűek nagy része nem ismeri fel a nyelvi hibákat és pontatlanságokat

Hosszú távú következmény:
mi lesz a statisztikai alapú nyelvi programokkal?